APRENDIZADO DE MÁQUINA · PPGCC/UFPI

Predição de Doença Cardíaca: Random Forest × Árvore de Decisão

Integrantes:

- Arthur Fernando Elvas Bohn — 20261001997
- Diego Cordeiro de Oliveira — 20261002180
- Keoma de Sousa Coelho — 20261004952

Professor:

- Dr. Vinicius Ponte Machado

PPGCC UFPI PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

2 Contexto

PERGUNTA DE PESQUISA

Trocar **1 árvore** por uma floresta de **300 árvores** melhora a triagem de doença cardíaca?

Classificação binária | Heart Failure (Kaggle) | 918 registros | 11 atributos | Teste: 184 pacientes

Erro mais grave

Falso negativo da classe 1

O paciente doente classificado como sadio fica **sem tratamento**.

102 doentes no conjunto de teste, cada FN é um deles sem diagnóstico

Métricas: recall e F1 da classe 1, além do F1 macro.

Mantido igual

- Split estratificado 80/20, semente 42 (734 / 184).
- CV `RepeatedStratifiedKFold` 5 × 2.
- Grade de **864 combinações**, refit por F1_c1.
- Ablação, engenharia, baseline e IC 95%.

O que muda

ANTES	AGORA
1 árvore	300 árvores

- **Aleatoriedade:** bootstrap + `max_features` por nó.
- **Extras:** OOB, dispersão das importâncias e nº de árvores.

O algoritmo é a **única variável alterada** → a diferença de resultado é atribuível ao modelo, não ao protocolo.

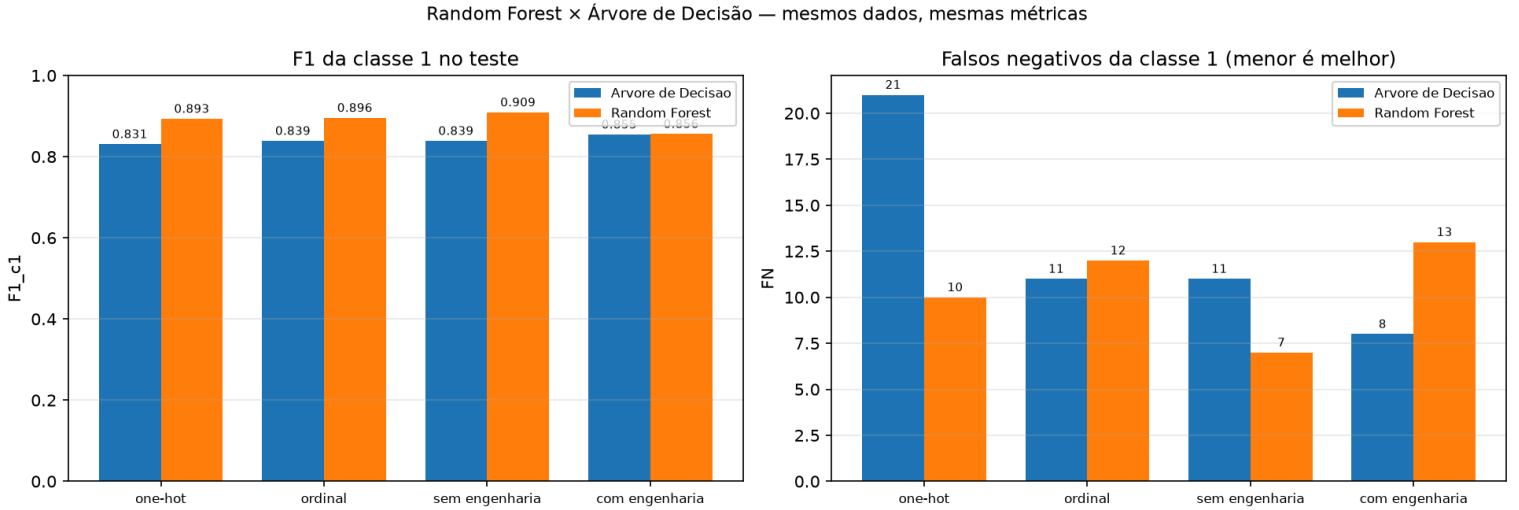
3 Grid Search: mesma grade e custo maior

Selecionado (Random Forest)	one-hot	ordinal
Comum às duas	`entropy` · `sqrt` · `balanced`	
max_depth / min_samples_leaf	None / 5	7 / 1
Imputação	mediana	média
Melhor F1_CV	**0,8809**	0,8799
OOB score	0,8583	0,8583
Tempo de busca	12,0 min	14,4 min

Métrica	Árvore de Decisão	Random Forest
Profundidade das árvores	3	**7,0 – 9,9**
Tempo de busca	segundos	**~26 min**
Runs no MLflow	111	**26**

4 Resultados: 4 cenários

Cenário	F1_c1 AD	F1_c1 RF	ΔF1_c1	FN AD	FN RF	F1_macro AD	F1_macro RF
one-hot	0,8308	0,8932	+0,0624	21	**10**	0,8200	0,8787
ordinal	0,8387	0,8955	+0,0568	11	12	0,8035	0,8849
sem engenharia	**0,8387**	**0,9091**	**+0,0704**	**11**	**7**	**0,8035**	**0,8948**
com engenharia	0,8545	0,8558	+0,0012	8	13	0,8192	0,8341



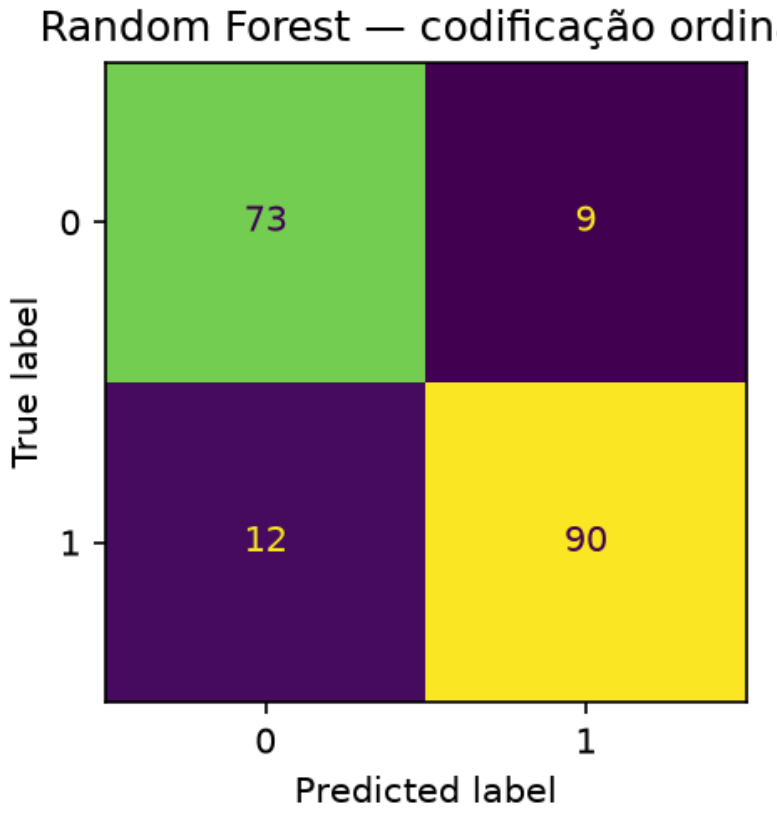
+0,0704
maior ganho de F1_c1, RF com os 11 atributos chega a **0,9091**

11FN (AD) → 7 FN (RF)
menos doentes sem diagnóstico no mesmo cenário

24FP (AD) → 12 FP (RF)
dados da melhor árvore (com engenharia, 8 FN). Baseline: F1_c1 0,7133 e 82 FP

5 Alvo da questão de pesquisa

Modelo (teste: 82 sadios, 102 doentes)	FP	FN	Recall_c1	F1_c1
RF sem engenharia	**12**	**7**	**0,9314**	**0,9091**
RF ordinal	**9**	12	0,8824	0,8955
RF one-hot	12	10	0,9020	0,8932
AD com engenharia	24	8	0,9216	0,8545
AD ordinal	24	11	0,8922	0,8387
AD one-hot	12	**21**	0,7941	0,8308
Baseline (maioria)	82	0	1,0000	0,7133



RF ordinal: menos alarmes falsos (9 FP) porém 12 FN

Trade-off

A melhor floresta erra **menos doentes** que a melhor árvore (7 × 8 FN) com **metade dos falsos positivos** (12 × 24). O baseline tem 0 FN, mas erra os 82 sadios.

6 Otimizações: ablação e engenharia de atributos

Ablação — F1_c1 ao remover um atributo

Cenário	Árvore	RF
todos os atributos	**0,8387**	**0,9091**
sem Oldpeak	**0,7647**	0,9005
sem MaxHR	**0,7890**	0,9005
sem ST_Slope	**0,7897**	0,8600
sem ChestPainType	**0,7647**	0,8400

RF vence nos **12 cenários de ablação em comparação com Árvore de Decisão** (Δ de +0,0585 a +0,1358). Nas duas abordagens, manter todos os atributos é o melhor.

Engenharia de atributos

Árvore de Decisão — sem → com

F1_c1 no teste	**0,8387 → 0,8545 ▲**
F1_CV	**0,8604 → 0,7946 ▼**

Ganho no teste não confirmado pela CV.

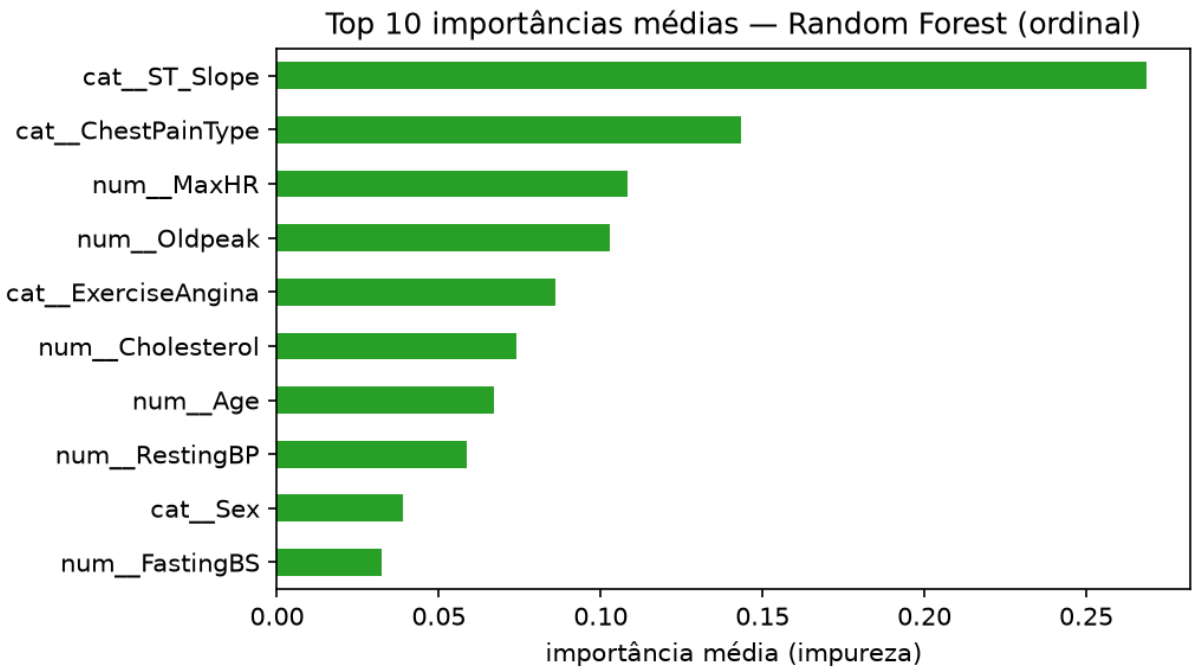
Random Forest — sem → com

F1_c1 no teste	**0,9091 → 0,8558 ▼**
Falsos negativos	**7 → 13 ▼**
F1_CV	**0,8744 → 0,8775 ≈**

Efeito oposto: piora a floresta no teste.

O ensemble compensa a variável ausente e já combina cortes para formar interações. As razões criadas para a árvore, viram ruído na floresta.

7 Como a floresta decide



Variável	Impureza	Desvio	Permutação ΔF1
ST_Slope	**0,2687**	0,1328	**0,1367**
ChestPainType	0,1432	0,0913	0,0391
MaxHR	0,1083	0,0539	0,0158
Oldpeak	0,1030	0,0602	0,0226

ST_Slope domina

Lidera nas duas medidas, mas com **desvio alto** entre as árvores: em algumas decide quase tudo, em outras é secundária.

Árvore de Decisão × Random Forest

AD: ExerciseAngina e ST_Slope na raiz. **RF:** decisão distribuída; ChestPainType sobe para 2º.

8 Análise do ganho

Modelo	F1_CV	F1_c1 teste	IC 95% F1_c1
AD ordinal	0,8604	0,8387	0,7817–0,8879
AD one-hot	0,8550	0,8308	0,7650–0,8865
RF ordinal	**0,8799**	**0,8955**	**0,8469–0,9368**
RF one-hot	**0,8809**	0,8932	0,8442–0,9347
RF sem engenharia	**0,8744**	**0,9091**	**0,8649–0,9469**

Validação Cruzada (CV)

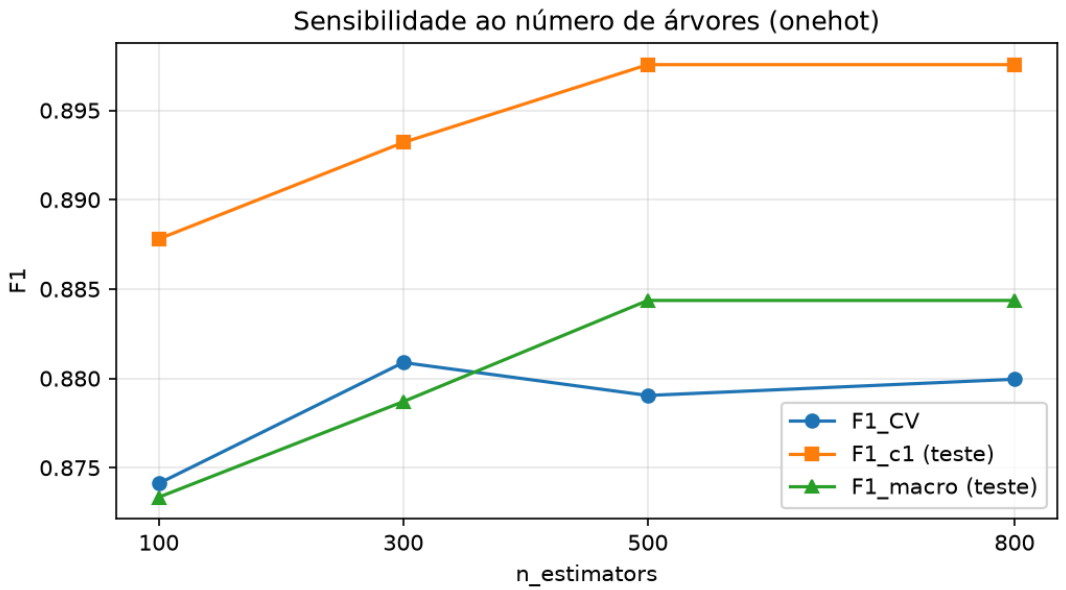
F1_CV **maior em todas** as configurações.

Intervalo de Confiança (IC 95%)

Intervalos **se sobrepõem**: vantagem consistente, mas não conclusiva com 184 pacientes.

OOB (*out-of-bag*)

Cada árvore é avaliada nas amostras que ficaram **fora do seu bootstrap**, uma validação interna, sem usar o teste. **0,8583** (630 de 734), coerente com a CV.



+0,0054
100 → 300 árvores

+0,0044
300 → 500 árvores

0
500 → 800 (idênticos)

9 Conclusão

0,9091
F1_c1 da melhor floresta (árvore: 0,8545)

7 FN
contra 8 da melhor árvore, com metade dos FP

0,8809
F1_CV da floresta (árvore: 0,8604)

~26 min
de busca, contra segundos da árvore

1. **Desempenho**
   Random Forest foi **superior em todos os cenários** → F1_c1, F1 macro e falsos positivos.

2. **Engenharia de atributos**
   Ajudou a Árvore de Decisão e **prejudicou a RF**.

3. **Interpretabilidade**
   AD oferece um **caminho auditável**, RF importância agregada e permutação.

Análise no ambiente de triagem

Usar o Random Forest com os 11 atributos. Manter a Árvoce de Decisão quando a **explicabilidade** do caminho de decisão for requisito.

Obrigado! Perguntas?