ENG. DE SOFTWARE PARA SISTEMAS INTELIGENTES · UFPI · M3

IFGuia: assistente de consulta às normativas de ensino do IFPI

Equipe:

- Sharon Wendy Feitosa Franca Rocha — Eng. de Dados
- Diego Cordeiro de Oliveira — Eng. de Machine Learning
- Guilherme Nonato de Sá Ribeiro — Eng. de Machine Learning
- Luis Felipe Ferreira de Castro — Eng. de Software

Demandante: PROEN/IFPI (Odimógenes Soares Lopes) · Professor: Dr. Guilherme Avelino

Entrega final do MVP · versão `v1.0-mvp` · 09/11/2026

PPGCC UFPI PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

2 Problema e objetivo

PROBLEMA (M1/M2)

Servidores e discentes não encontram nem interpretam com segurança as normativas de ensino do IFPI, dispersas em PDFs, muitos digitalizados.

Resoluções do CONSUP

1.449 PDFs

PDF nativo, misto e escaneado

30–40% do tempo da PROEN

Negócio

Reduzir a dependência dos especialistas da PROEN e uniformizar a interpretação entre os campi.

Sistema

Responder em linguagem clara, **sempre citando** documento, artigo e vigência; **recusar** quando não há evidência.

Modelo

Recuperar o trecho certo e gerar a resposta **só com ele**, sem informação de fora.

Erro mais grave

Resposta errada com **citação aparentemente válida** (ou norma revogada citada como vigente). Recusar custa só tempo: é o cenário de hoje.

Papel do assistente

Apoio à decisão, com supervisão humana. A decisão final continua com a PROEN.

3 Escopo implementado no MVP

Entregue e demonstrável

- **Ingestão do acervo completo:** 1.446 de 1.449 PDFs; extração com OCR, gate de qualidade e carga incremental.
- **Metadados e vigência** por documento (vigente, alterada, revogada, cancelada), revisáveis no admin.
- **Chunking por artigo** e índices versionados (BM25 + ChromaDB/bge-m3) com busca híbrida.
- **Geração com citação obrigatória**, recusa, aviso de vigência e guardrails.
- **Aplicação web + API** (`/v1/consulta`, `/v1/feedback`) e admin com fila de revisão da PROEN.
- **Golden set** (56 perguntas), harness de avaliação, Docker e **305 testes** automatizados.

Fora do escopo

- SUAP e dados de discentes (LGPD).
- SSO e implantação na DTI.
- Fine-tuning de LLM ou de embeddings.
- Grafo completo de revogações.
- Reranking, Airflow e alertas.

Publicado em **https://ifguia.professordiegocordeiro.com.br/** · código na tag **v1.0-mvp** (commit **b50a37b**).

4 Cenário principal: da pergunta à resposta citada

1 **Pergunta**
"Quais os requisitos para a colação de grau?"

→

2 **Guardrails**
escopo, injeção, dados pessoais

→

3 **Busca híbrida**
trechos + artigos vizinhos

→

4 **LLM**
responde só com os trechos

→

5 **Verificação**
citações e confiança

→

6 **Tela + feedback**
fila da PROEN

O que o usuário vê

- Resposta com citações **[n]** ligadas aos trechos, ao documento e ao artigo.
- **Vigência** da norma e selo de **confiança** (alta, média, baixa).
- Aviso fixo: o assistente **não substitui a norma**.
- Sem evidência ou fora do escopo: **recusa** com encaminhamento à PROEN.
- Botão útil / não útil + comentário → **fila de revisão** no admin.

Demonstração ao vivo

ifguia.professordiegocordeiro.com.br

Servidor dedicado com HTTPS

5 Arquitetura e componentes

A
Pipeline de ingestão
PyMuPDF + OCR (Tesseract) → gate Jev → JSONL aprovados / rejeitados

→

B
Núcleo `src/rag`
normalização, metadados, vigência, chunking, índices, consulta

→

C
Django
telas, API, admin, logs e feedback (SQLite)

→

D
Publicação
gunicorn + Nginx + HTTPS, em Docker

Modelos (FMware)

Sem treinamento próprio. `BAAI/bge-m3` local para embeddings; `deepseek-flash` por API para gerar; `jev-latest` (TypeSafe) no gate.

Provedor atrás de interface única (Ollama local suportado).

Dados

903 documentos aprovados (56.834 trechos) e **543** de baixa confiabilidade (15.937 trechos).

Índices **versionados e imutáveis**; a versão ativa fica em `ATIVO.json` (rollback por troca de arquivo).

Infraestrutura

Linux x86_64 com **4 vCPU, 8 GB de RAM, 100 GB SSD**, sem GPU.

ADR 0002: **Django no lugar do FastAPI** — interface, admin da PROEN e API num só serviço.

6 Decisão 1 · Dados: extração, gate e baixa confiabilidade

Como o acervo entra

- **Extração por trilha:** texto nativo pelo PyMuPDF; páginas escaneadas pelo OCR.
- **Gate de qualidade (Jev):** um LLM avaliador dá nota de legibilidade e verifica se os metadados da norma sobreviveram à extração.
- **Aprovados (903)** formam o índice principal.
- **Reprovados (543)** não ficam de fora: vão para um índice de **baixa confiabilidade**, usado só como complemento, com aviso na tela.

Gate de qualidade

Filtro antes do índice: só texto legível vira evidência plena (requisito R4 do M2).

Score (1–5) e noul

Score = legibilidade do texto. Noul = probabilidade de os metadados (norma, número, data, artigo) estarem preservados. Aprova com score ≥ 2 e noul ≥ 0,50.

Baixa confiabilidade

Entra com peso 0,5 na busca, no máximo 2 trechos, relevância ≥ 0,65 e confiança limitada a 0,39.

Mudança de escopo: o M2 previa excluir os reprovados; o MVP os mantém sinalizados, para nenhuma norma vigente ficar fora da resposta.

7 Decisão 2 · Chunking: `artigo` × `paragrafo`

Chunking (fatiamento)

Dividir cada documento em trechos menores. O trecho é a unidade que a busca encontra e que a resposta cita.

`paragrafo` — baseline do M2

- Blocos de até **1.200 caracteres** com **150 de sobreposição**.
- Simples, mas corta artigos ao meio e não sabe qual dispositivo citar.

`artigo` — adotado

- **Um trecho por artigo** (Art. 5º), com o dispositivo guardado para a citação.
- Artigo longo dividido em parágrafos (§) e partes; regulamentos anexos ganham o prefixo “Anexo”.
- Trata erros do OCR (“Art. 72” lido no lugar de “Art. 7º”) e marca o dispositivo como incerto.

A citação vira **“Resolução nº 253/2025, Art. 53”** — verificável pelo usuário, que é o que a PROEN pediu.

8 Decisão 3 · Busca: bm25, dense e hybrid

bm25 — lexical

Pontua o trecho pelas **palavras em comum** com a pergunta, valorizando termos raros. Ótimo para "Art. 53", "trancamento". É o **baseline** do M2.

dense — semântica

Converte pergunta e trecho em vetores (**embeddings** do bge-m3, 1.024 dimensões) e compara o **significado**, mesmo com outras palavras. Vetores no ChromaDB.

hybrid — adotado

Junta as duas listas pela **fusão RRF** (Reciprocal Rank Fusion): soma 1/(60 + posição) de cada método, com **peso do BM25** ajustável.

Contexto enviado ao LLM

- **k = 8** trechos principais, escolhidos entre 50 candidatos por método.
- **Artigos vizinhos:** o anterior e o seguinte de cada trecho, até 8 extras.
- **Deduplicação:** mesmo artigo em duas versões → fica a norma mais recente.

Relevância e limiares

- **Relevância (0–1):** maior entre o cosseno da busca densa e o BM25 saturado.
- Trecho abaixo de **0,35** não conta como evidência.
- Norma **revogada** nunca é evidência: aparece à parte, sinalizada.

A literatura do M2 apontava o híbrido com bge-m3 como melhor arranjo; o MVP mediu os três modos no nosso acervo (slide 11).

9 Decisão 4 · Geração e salvaguardas

Geração

- **Prompt versionado (v3)**: responde só com os trechos numerados, cita cada afirmação e admite resposta parcial quando falta parte.
- **Temperatura 0**, até 700 tokens, timeout de 30 s.
- **Verificação da saída:** citação inexistente ou resposta sem citação vira recusa.
- **Confiança** = relevância dos trechos citados × cobertura de citação; abaixo de **0,40** recusa.

Salvaguardas

- **Guardrails de entrada:** escopo (legislação federal, caso individual), detecção de injeção e máscara de dados pessoais.
- **Fallback "somente busca"** se o provedor falhar.
- **Supervisão humana:** feedback por resposta e fila da PROEN para confiança média, feedback negativo e injeção suspeita.
- **Logs** com latência, custo e versões (prompt, modelo, índice).

Projeto orientado ao erro mais grave: **na dúvida, recusa** e encaminha à PROEN.

10 Como avaliamos: golden set e harness

GOLDEN SET (VERSÃO 1C8902A7)

56 perguntas: 40 factuais, 5 fora do acervo, 5 fora do escopo, 3 sobre normas revogadas e 3 de injeção — cada factual com documento e artigo esperados.

`run_evals`: busca + resposta

`ajustar_busca`: calibração sem LLM

relatório versionado

Recall@k (corte k = 5)

Fração das perguntas em que o artigo esperado aparece entre os **5 primeiros** resultados.

IC 95% (Wilson)

Intervalo de confiança da taxa; com n = 40 ele é **largo**, e 1–2 perguntas são ruído.

Recusa correta / falsa recusa

Recusou o que devia × recusou pergunta que tinha resposta.

MRR

Média de 1/posição do primeiro acerto: mede se o acerto vem **no topo**.

Recall do contexto

O artigo esperado chega ao que **vai para o LLM** (k, vizinhos, deduplicação)?

Acerto / precisão de citação

Cita o artigo esperado? Que fração das citações está nele?

11 Resultados · Recuperação (40 perguntas factuais)

Recall@5 por modo (configuração adotada)



Modo	Recall@5	IC 95%	MRR	Doc.
BM25	0,57	0,42–0,71	0,45	0,75
Denso	0,68	0,52–0,80	0,48	0,75
Híbrido	**0,62**	**0,47–0,76**	**0,49**	**0,80**

Leitura

O híbrido **supera o baseline** e tem o melhor MRR e recall de documento. Com peso 0,5 chega a **0,725**, mas recusa menos (slide 12). Com k = 8 e vizinhos, o artigo certo chega ao LLM em **80%** das perguntas.

Os intervalos se sobrepõem: com 40 perguntas, a diferença entre os modos é indício, não prova.

12 Resultados · Resposta com o LLM (56 perguntas)

EVOLUÇÃO DAS RODADAS: BASE_V1 (PROMPT V1, K = 5) → V3 → CANDIDATO A (PESO 0,5) → CANDIDATO B (PESO 1,0, ATÉ 8 VIZINHOS) — ADOTADO

Recusa correta

base_v1	v3	cand. A	cand. B
71%	71%	80%	100%

Meta do M2: ≥ 90%

Falsa recusa

base_v1	v3	cand. A	cand. B
21%	8%	8%	8%

3 de 40 factuais

Acerto de citação

base_v1	v3	cand. A	cand. B
19%	72%	81%	81%

Cita o artigo esperado

100%
citações válidas · 0 saídas bloqueadas

0
respostas citando norma não vigente

2,45 s
latência p95 (meta ≤ 15 s)

US$ 0,0006
por consulta (US$ 0,036 por 56)

13 Critérios de aceite do M2 × resultado

Cenário ou requisito (M2)	Meta	Resultado no MVP	Situação
R1 · Respostas com citação para trecho existente	100%	100% (0 bloqueadas)	Atendido
R2 · Recusa nas perguntas sem resposta no acervo	≥ 90%	100% (n = 10)	Atendido
R3 · Recall@k comparado ao BM25	≥ 0,70	0,62 (BM25 0,57); contexto 0,80	Parcial
Fidelidade das respostas (M2, seção 7)	≥ 0,85	não medida (anotação manual pendente)	Pendente
H3 · Vigência	nenhuma revogada como vigente	0 citações não vigentes; revogada sinalizada em 2 de 3	Parcial
R4 · Só documento aprovado como evidência plena	auditoria	903 no índice principal; 543 à parte, com aviso	Atendido
Guardrails e degradação	injeção e falha do provedor	injeção detectada em 100% (n = 3); modo “somente busca” testado	Atendido
R5 · Reprodutível e p95 ≤ 15 s	Docker + p95	Docker, 305 testes, p95 2,45 s; sem CI e sem teste por terceiros	Parcial
Fluxo prioritário demonstrável	ponta a ponta	publicado com HTTPS; 77 consultas registradas	Atendido

Conclusão do modelo: atende com restrições — as salvaguardas estão cumpridas; recuperação e fidelidade ainda não.

14 Backlog e mudanças de escopo

22 entregues

das 31 tarefas dos incrementos 1–3 (GitHub Projects, issues #8–#38)

6 parciais

dump compartilhado, golden set validado, noul, ajuste final, teste ponta a ponta, runbook

3 não entregues

CI (#9), ground truth com dupla anotação (#27), execução por terceiros (#36)

O que mudou em relação ao M2

- **FastAPI → Django** (ADR 0002): telas, admin e API num só serviço.
- **Painel da PROEN antecipado** como admin do Django (logs, fila, vigência).
- **Reprovados no gate** viraram índice de baixa confiabilidade, em vez de excluídos.
- **Acrescentados:** carga incremental, diagnóstico do ambiente, vizinhos e deduplicação, prompt v3.
- **Removidos/adiados:** MLflow, Airflow e template de ML (ADR 0008); reranking; LLM local não avaliado.

15 Análise de erros, limitações e riscos

Onde o sistema erra

- **Falsa recusa (8%):** acha o documento certo, mas outro artigo dele.
- **Precisão de citação (44%):** cita também os vizinhos — correto, porém menos enxuto.
- **Vigência:** 1 de 3 revogadas sem sinalização; vigência vem do nome do arquivo + revisão manual.
- **Tabelas e OCR:** 543 documentos com OCR inválido (347) ou tabela corrompida (150); perguntas sobre quadros (oferta de vagas) são o pior caso.

Limitações e riscos para uso real

- **Golden set pequeno e não validado pela PROEN** (só pela equipe, por falta de agenda); perguntas escritas lendo os artigos favorecem o BM25.
- **Fidelidade não medida.**
- Dependência das APIs **DeepSeek e TypeSafe** (custo, disponibilidade, envio de texto público).
- Listas extensas (“todos os cursos de 2027”) recebem resposta **parcial**.
- Consulta pública sem autenticação; sem CI.

16 Em andamento e próximos passos

202 / 543
reprovados passam no gate com a nova extração

0,62 → 0,65
Recall@5 do híbrido

0,80 → 0,85
recall do documento, com recusa correta mantida em 100%

100% → 33%
falsa recusa nas perguntas da Res. 40/2026

Em andamento: branch `exp/extracao-tabelas`

- Tabelas em Markdown com espaços nas células e cabeçalho repetido em cada trecho.
- OCR com binarização; Jev sobre o texto normalizado.
- Vagas reservadas para a baixa confiabilidade e prioridade ao ano citado na pergunta.
- Será mesclado após os testes da equipe na aplicação web.

Pendências priorizadas

- Validar o golden set com a PROEN e **anotar a fidelidade**.
- Configurar a **CI** (#9) e o teste por terceiros (#36).
- Runbook com responsáveis (#37); senhas do admin, monitoramento e backup.
- Ampliar o ground truth do gate com dupla anotação (#27).
- Depois: perguntas reais no golden set, reranking, LLM local, grafo de vigência.

17 Recomendação para a banca

Avançar ao piloto | **Retornar para ajustes curtos → piloto controlado** | Não avançar

Por que está pronto para um piloto controlado

- Fluxo completo **publicado** e executável.
- Salvaguardas do erro grave cumpridas: **100%** citações válidas, **100%** recusa correta, **0** norma revogada como vigente.
- Supera os baselines (BM25; base_v1) com p95 de 2,45 s e custo desprezível.

Condições antes do piloto

- Golden set **validado pela PROEN** e fidelidade medida (meta ≥ 0,85).
- **CI** e teste de execução por terceiros.
- Mesclar o experimento de tabelas se confirmar o ganho.

Piloto: servidores da PROEN, perguntas reais, linha de base de tempo medida.

Pedido à banca: aceitar o MVP e autorizar o piloto controlado após as três condições acima.

18 Obrigado! Perguntas?

ifguia.professordiegocordeiro.com.br

Aplicação publicada

github.com/SE4AI-UFPI/IFGuia · tag v1.0-mvp

Código, README, ADRs e relatórios de avaliação

IFGuia · resposta com citação, recusa quando não sabe e a decisão final com a PROEN.

19 Apêndice · Glossário para a arguição

RAG
Geração aumentada por recuperação: busca trechos e o LLM responde só com eles.

FMware
Software construído sobre modelos fundacionais prontos, sem treinar modelo próprio.

Embedding
Vetor numérico que representa o significado de um texto.

Baseline
Referência simples para comparar: BM25 na busca, base_v1 na resposta.

k e candidatos
k = trechos enviados ao LLM (8); candidatos = resultados de cada método antes da fusão (50).

Peso do BM25
Quanto a lista lexical vale na fusão RRF (o denso vale 1,0).

Golden set
Conjunto de perguntas com resposta esperada, usado como gabarito.

p50 / p95
Latência mediana e a que 95% das consultas não ultrapassam.

Fidelidade
Fração da resposta sustentada pelos trechos; medida por anotação humana.

Guardrail
Regra automática na entrada ou na saída (escopo, injeção, citação).

Injeção de prompt
Texto que tenta fazer o modelo ignorar as instruções.

Índice versionado
Cada reconstrução cria uma versão nova e imutável; `ATIVO.json` aponta a vigente.