APRENDIZADO DE MÁQUINA · PPGCC/UFPI

Predição de Atividade de Moléculas com Redes Neurais

Integrantes:

- Arthur Fernando Elvas Bohn — 20261001997
- Diego Cordeiro de Oliveira — 20261002180
- Keoma de Sousa Coelho — 20261004952

Professor:

- Dr. Vinicius Ponte Machado

PPGCC UFPI PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

2 O problema: encontrar candidatos a medicamento

PERGUNTA DE PESQUISA

Dada apenas a **estrutura química** de uma molécula, é possível prever se ela age sobre uma proteína-alvo?

Classificação binária | ChEMBL (dados reais) | 58.736 medições | 4 proteínas-alvo | Rede neural (MLP)

Como se mede a potência

Um ensaio mede **qual concentração** da molécula é necessária para produzir o efeito na proteína.

Quanto menor a concentração, mais potente a molécula.

Se você precisa de **muito pouquinho** (uma gota) para fazer efeito, a molécula é **muito potente**.

Ex.: `IC50` = concentração que reduz à metade a atividade da proteína.

A escala pCHEMBL

pCHEMBL = $-\log_{10}$(mol/L)

A escala **pChEMBL** usa o logaritmo para transformar concentrações minúsculas (cheias de zeros) em uma nota simples de 1 a 10. Assim, quanto **maior a nota**, mais potente é a molécula, onde cada ponto extra significa precisar de **10 vezes menos substância** para o mesmo efeito.

pCHEMBL 6 ≈ 1 µM · **6,5 ≈ 316 nM** (3,2x mais potente)· 7 ≈ 100 nM (10x mais potente)

Erro mais grave

Falso negativo

Descartar uma molécula que **era** ativa o candidato se perde e nunca chega ao ensaio.

Um falso positivo só gasta um ensaio. Por isso priorizamos **revocação e F1 da classe ativa**.

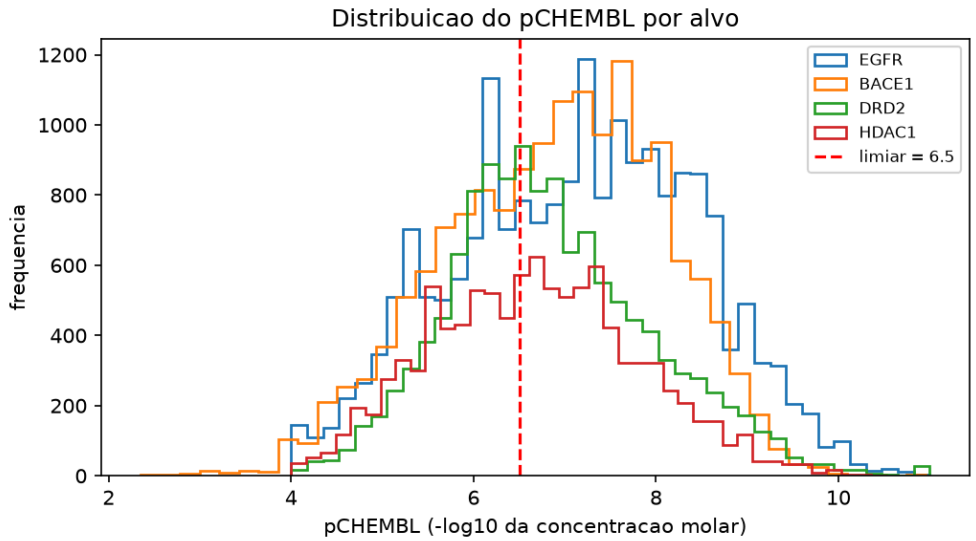
Definimos classe 1 = ativa (pCHEMBL ≥ 6,5) e classe 0 = inativa. O rótulo não vem pronto, é construído na preparação dos dados.

3 A base

Alvo	O que é	Moléculas
EGFR	Receptor de crescimento — **câncer**	10.601 · 64% ativas
BACE1	Enzima amiloide — **Alzheimer**	9.990 · 62% ativas
DRD2	Receptor de dopamina — **psiquiatria**	8.392 · 57% ativas
HDAC1	Enzima de genes — **câncer**	8.003 · 54% ativas

Quatro modelos

Apenas **71 de 37 mil moléculas** foram testadas em mais de um alvo. Os conjuntos são praticamente independentes → **um modelo por proteína**.



Distribuição da potência, linha tracejada corte em 6,5

53% – 64%
de moléculas ativas: desbalanceamento leve, sem reamostragem

6,7 – 7,2
pCHEMBL mediano: distribuições simétricas e comparáveis

4 O desafio a base não tem atributos

DIFERENÇA PARA OS TRABALHOS ANTERIORES

Antes recebíamos uma tabela pronta (idade, colesterol...). Aqui a única informação é a estrutura da molécula, escrita como texto e rede neural não lê texto.

SMILES

Notação que descreve átomos e ligações como uma cadeia de caracteres.

```
CCO        → etanol
CC(=O)O    → ácido acético
```

Texto de **tamanho variável**: precisa virar um vetor de tamanho fixo.

Opção A — *Fingerprint* de Morgan

Percorre cada átomo e registra os **fragmentos** ao redor dele.

Resultado: **2.048 bits,** cada posição diz se um fragmento existe (1) ou não (0).

É a "impressão digital" da estrutura.

Opção B — Descritores

Calcula **propriedades globais** da molécula.

Massa molecular, lipofilicidade (logP), área polar, nº de anéis... **205 números**.

Descreve como a molécula *é*, não quais fragmentos tem.

Testamos as duas e também a combinação (2.253 atributos). Essa é a principal transformação comparada no trabalho.

5 Preparação dos dados: cinco etapas

1. **Filtrar a proteína** — os quatro alvos são tratados separadamente.
2. **Padronizar o tipo de medida** — manter só `IC50` e `Ki` (afinidade); descartar EC50 e similares, que medem outra coisa.
3. **Remover o não confiável** — duplicatas marcadas pelo ChEMBL (12,5%) e registros sem estrutura.
4. **Validar as estruturas** — todo SMILES passa pelo interpretador químico.
5. **Agregar por molécula** — várias medições da mesma molécula viram **uma**, pela mediana.

Por que a etapa 5 é a mais importante

30% das moléculas foram medidas mais de uma vez, em ensaios diferentes.

Sem agregar, a **mesma molécula** cairia no treino *e* no teste.

vazamento — o modelo "acertaria" aquilo que já tinha visto, e o resultado relatado seria falso

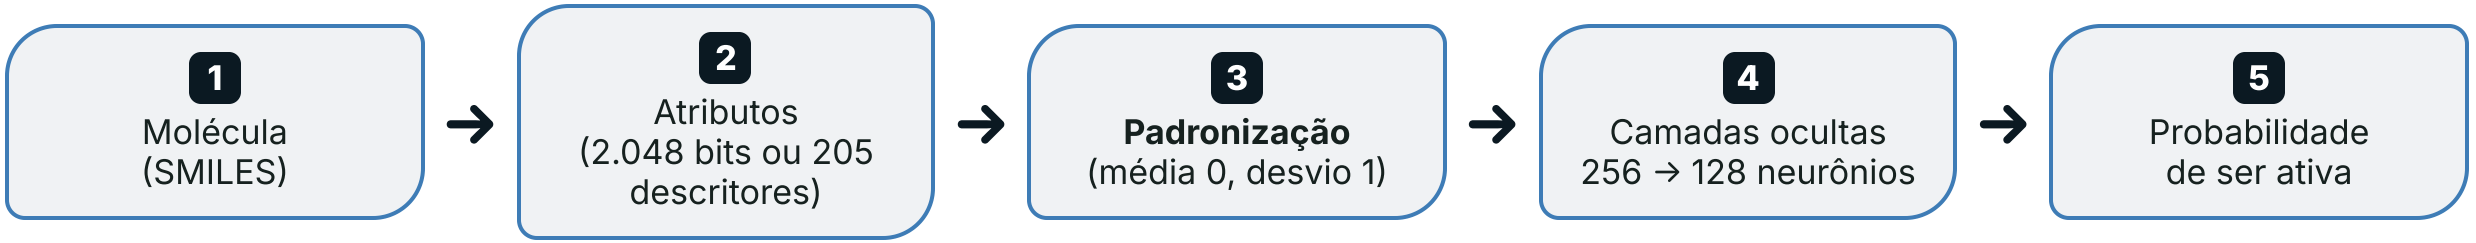
EGFR — efeito da preparação

Medições do alvo	19.866
Após filtros	16.599
Moléculas únicas	10.601 ▼

Cada molécula foi medida 1,57 vez em média.

Usamos a mediana, e não a média: ela resiste a medições discrepantes entre laboratórios diferentes.

6 A rede neural e busca de hiperparâmetros



Hiperparâmetro	Valores testados	Papel
Arquitetura	(128) · (256,128) · (128,64)	Capacidade da rede
Ativação	`relu` · `tanh`	Não linearidade
alpha	0,0001 · 0,001	Freia o sobreajuste
Taxa de aprendizado	0,001 · 0,0005	Tamanho do passo
Total	**24 combinações** × 5 partições × 12 cenários = **1.440 ajustes**	

Como escolhemos

- **Validação cruzada** em 5 partições: o modelo é treinado e testado 5 vezes, em recortes diferentes do treino.
- Critério de seleção: **F1 da classe ativa**.
- Os **20% de teste** ficam isolados até o fim.

~23 min
de busca total

86 runs
registradas no MLflow

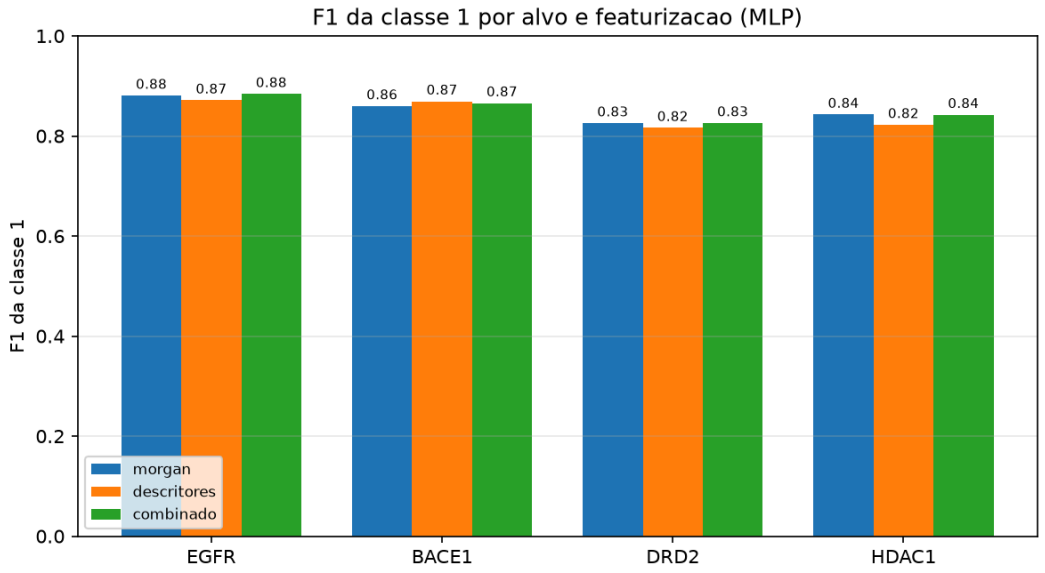
A etapa 3 do fluxo, padronização, parece um detalhe técnico. O slide 8 mostra que é ela que decide se o modelo funciona.

7 Resultados:

Alvo	Melhor representação	F1 ativa	IC 95%	ROC-AUC	Referência ingênua (F1 macro)
EGFR	Combinado	**0,8840**	0,871–0,896	0,9023	0,3916
BACE1	Descritores	0,8693	0,855–0,884	0,8934	**0,3816**
HDAC1	*Fingerprint*	0,8428	0,823–0,860	0,8996	**0,3492**
DRD2	Combinado	0,8259	0,806–0,844	0,8744	**0,3638**

As três representações empatam

Dentro de cada alvo, *fingerprint*, descritores e combinação ficam **dentro do mesmo intervalo de confiança** → a diferença **não é conclusiva**.



As três barras de cada alvo são praticamente da mesma altura

2×
o F1 macro da referência ingênua (0,80–0,84 contra 0,35–0,39)

DRD2
o alvo mais difícil, em todas as métricas

8 A padronização decide

Alvo	ROC-AUC com padronização	ROC-AUC sem	F1 ativa sem
EGFR	**0,9023**	0,5115	0,7864
BACE1	**0,9049**	0,4809	0,0000
DRD2	**0,8744**	0,5126	0,7224
HDAC1	**0,9120**	0,5090	0,7014

0,50 = acaso

Sem padronizar, a ROC-AUC cai para **0,48–0,51** nos quatro alvos: o modelo vira um **sorteio**. No BACE1 ele colapsa e não identifica **nenhuma** das 1.233 moléculas ativas.

Por quê?

A rede soma todos os atributos na mesma conta. Sem padronizar:

Ordens de grandeza

Massa molecular	~300
Nº de anéis	0 a 5
Bits do *fingerprint*	0 ou 1

A massa domina a conta e os demais atributos somem.

Cuidado com uma métrica só

Em três alvos, o F1 *sem* padronização ainda parece razoável (0,70–0,79). É ilusão: a ROC-AUC de 0,51 revela que não há discriminação alguma.

Uma árvore de decisão não teria esse problema: ela é invariante à escala. A transformação necessária depende do algoritmo, não só dos dados.

9 Conclusão

0,826 – 0,884
F1 da classe ativa nos quatro alvos

0,863 – 0,905
ROC-AUC (0,5 seria acaso)

0,50
ROC-AUC sem padronizar: o modelo morre

1.440
ajustes, 86 runs no MLflow

1. **Padronização é indispensável**
   Única transformação cuja ausência **inviabiliza** o modelo.

2. **Representação não é determinante**
   Fingerprint, descritores e combinação **empatam** → escolher o mais barato.

3. **Limiar muda o equilíbrio, não a capacidade**
   Subir o corte derruba o F1, mas a **ROC-AUC se mantém**.

4. **Hiperparâmetros atingiu um platô**
   Teste de GRID 6 vezes maior não mudou o resultado no teste.

5. Bioatividade alta **não garante** bom medicamento, a predição indica um *hit* e filtros candidatos com **ADMET (Absorção, Distribuição, Metabolismo, Excreção e Toxicidade)** devem ser combinados.

Obrigado! Perguntas?