APRENDIZADO DE MÁQUINA · PPGCC/UFPI

Predição de Atividade de Moléculas com Redes Neurais

Integrantes:

- Arthur Fernando Elvas Bohn — 20261001997
- Diego Cordeiro de Oliveira — 20261002180
- Keoma de Sousa Coelho — 20261004952

Professor:

- Dr. Vinicius Ponte Machado

PPGCC UFPI PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

2 Redes Neurais

O que é uma rede neural?
Modelo computacional que aprende **padrões** a partir de dados, ajustando **pesos** para minimizar o erro entre predição e valor observado.

Elementos principais

- Camada de entrada: recebe os atributos
- Camadas ocultas: combinam sinais e extraem padrões
- Camada de saída: gera a predição
- Funções de ativação: adicionam não linearidade
- Pesos e vieses: parâmetros ajustáveis

Como aprende?

- Propaga entradas e compara com valor real
- Calcula o erro (função de perda)
- Backpropagation ajusta pesos para reduzir o erro
- Repete por várias épocas
- Generalização avaliada em dados não vistos

Neste trabalho a rede mapeia descritores moleculares para atividade biológica.

3 O problema: encontrar candidatos a medicamento

PERGUNTA DE PESQUISA

Dada apenas a **estrutura química** de uma molécula, é possível prever se ela age sobre uma proteína-alvo?

Classificação binária | ChEMBL (dados reais) | 58.736 medições | 4 proteínas-alvo

Como se mede a potência

Um ensaio mede **qual concentração** da molécula é necessária para produzir o efeito na proteína.

Quanto menor a concentração, mais potente a molécula.

Se você precisa de **muito pouquinho** (uma gota) para fazer efeito, a molécula é **muito potente**.

Ex.: `IC50` = concentração que reduz à metade a atividade da proteína.

A escala pCHEMBL

$pCHEMBL = -\log_{10}(mol/L)$

A escala **pChEMBL** usa o logaritmo para transformar concentrações minúsculas (cheias de zeros) em uma nota simples de 1 a 10. Assim, quanto **maior a nota**, mais potente é a molécula, onde cada ponto extra significa precisar de **10 vezes menos substância** para o mesmo efeito.

pCHEMBL 6 ≈ 1 µM · **6,5 ≈ 316 nM** (3,2x mais potente)· 7 ≈ 100 nM (10x mais potente)

Erro mais grave

Falso negativo

Descartar uma molécula que **era** ativa o candidato se perde e nunca chega ao ensaio.

Um falso positivo só gasta um ensaio. Por isso priorizamos **revocação e F1 da classe ativa**.

Classe 1 = ativa (pCHEMBL ≥ 6,5); **classe 0 = inativa**.
O rótulo **não vem pronto** foi construído na preparação dos dados.
Limiar escolhido por dar, nos quatro alvos, a divisão mais equilibrada, desequilíbrio atrapalha treino e métricas.

4 A base

Dicionário de atributos da base de dados

Coluna	Descrição
`protein / target_chembl_id`	Proteína-alvo e seu identificador no ChEMBL
`molecule_chembl_id`	Identificador da molécula testada
`canonical_smiles`	Estrutura química da molécula em notação SMILES
`assay_chembl_id / assay_type`	Identificador e tipo do ensaio (todos do tipo B, de ligação)
`standard_type`	Tipo da medida: IC50, Ki, Kd, EC50, AC50 ou ED50
`standard_relation`	Relação da medida (todos iguais a '=', valores exatos)
`standard_value / standard_units`	Valor medido e unidade (todos em nM)
`pchembl_value`	Potência em escala logarítmica: $-\log_{10}$ da concentração molar
`data_validity_comment`	Observação de validade (vazia em todos os registros)
`potential_duplicate`	Indicador de possível duplicata do registro (1 = suspeita)
`activity_id`	Identificador único da medição

Observação

Várias colunas são constantes e, portanto, sem poder preditivo. Os atributos efetivamente utilizados pelo modelo derivam do `canonical_smiles`.

5 A base

Alvo	O que é	Moléculas
EGFR	Receptor de crescimento — **câncer**	10.601
BACE1	Enzima amiloide — **Alzheimer**	9.990
DRD2	Receptor de dopamina — **psiquiatria**	8.392
HDAC1	Enzima de genes — **câncer**	8.003

Quatro modelos

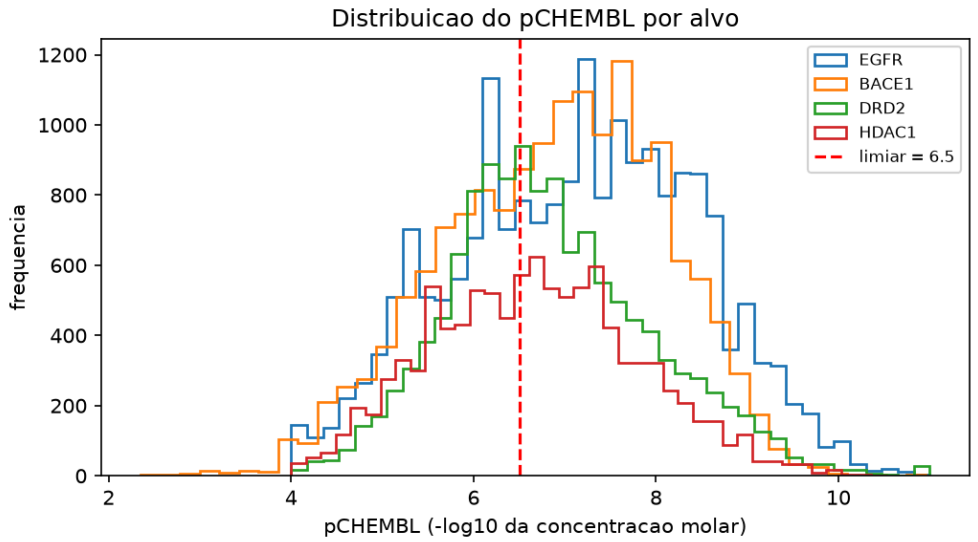
Apenas **71 de 37 mil moléculas** foram testadas em mais de um alvo. Os conjuntos são praticamente independentes → **um modelo por proteína**.

53% – 64%

de moléculas ativas: desbalanceamento leve, sem reamostragem

6,7 – 7,2

pCHEMBL mediano: distribuições simétricas e comparáveis



Distribuição da potência, linha tracejada corte em 6,5

6 A base não tem atributos

DIFERENÇA PARA OS TRABALHOS ANTERIORES

Antes recebíamos uma tabela pronta (idade, colesterol...). Aqui a única informação é a estrutura da molécula, escrita como texto e rede neural não lê texto.

SMILES

Notação que descreve átomos e ligações como uma cadeia de caracteres.

```
CCO        → etanol
CC(=O)O    → ácido acético
```

Texto de **tamanho variável**: precisa virar um vetor de tamanho fixo.

Opção A — *Fingerprint* de Morgan

Percorre cada átomo e registra os **fragmentos** ao redor dele.

Resultado: **2.048 bits,** cada posição diz se um fragmento existe (1) ou não (0).

É a "impressão digital" da estrutura.

Opção B — Descritores

Calcula **propriedades globais** da molécula.

Massa molecular, lipofilicidade (logP), área polar, nº de anéis... **205 números**. Os descritores que resultaram em valores indefinidos ou infinitos para alguma molécula foram removidos.

Descreve como a molécula *é*, não quais fragmentos tem.

Testamos as duas e também a combinação (2.253 atributos).

7 Preparação dos dados

1. **Filtrar a proteína** — os quatro alvos são tratados separadamente.
2. **Padronizar o tipo de medida** — manter só `IC50 (Inibição)` e `Ki(Afinidade)`; juntos respondem por 95,7% dos registros. Descartar EC50 e similares somam pouco mais de 4%.
3. **Remover o não confiável** — duplicatas marcadas pelo ChEMBL (12,5%) e registros sem estrutura.
4. **Validar as estruturas** — todo SMILES passa pelo interpretador químico (biblioteca RDKit).
5. **Agregar por molécula** — várias medições da mesma molécula viram **uma**, pela mediana.

Etapa 5 é muito importante

30% das moléculas foram medidas mais de uma vez, em ensaios diferentes.

Sem agregar, a **mesma molécula** cairia no treino *e* no teste.

vazamento o modelo "acertaria" aquilo que já tinha visto, e o resultado relatado seria falso

Alvo	Moléculas	Treino	Teste	Teste classe 0	Teste classe 1	% ativos
EGFR	10.601	8.480	2.121	756	1.365	64,3%
BACE1	9.990	7.992	1.998	765	1.233	61,7%
DRD2	8.392	6.713	1.679	719	960	57,2%
HDAC1	8.003	6.402	1.601	742	859	53,6%

Treinamento / Teste

Conjuntos de treinamento e teste por alvo (após a preparação: 80% treino, 20% teste)

Classe 1 = molécula ativa; classe 0 = inativa.

Exemplo (EGFR): aprende com 8.480 moléculas e avaliado em 2.121 que nunca viu.

8 A rede neural e busca de hiperparâmetros



Hiperparâmetro	Valores testados	Papel
Arquitetura (hidden_layer_sizes)	(128) · (256,128) · (128,64)	Capacidade da rede
Ativação (activation)	`relu` · `tanh`	Não linearidade
alpha	0,0001 · 0,001	Freia o sobreajuste
Taxa de aprendizado inicial (learning_rate_init)	0,001 · 0,0005	Tamanho do passo
Total	**24 combinações** × 5 partições × 12 cenários = **1.440 ajustes**	

Observações

- **Validação cruzada** em 5 partições: o modelo é treinado e testado 5 vezes, em recortes diferentes do treino.
- Critério de seleção: **F1 da classe ativa**.
- Os **20% de teste** ficam isolados até o fim.
  sem melhora
- Fixo o número máximo de iterações (300).
- Parada antecipada com 10% do treino.
- Refit foi o F1 da classe 1.

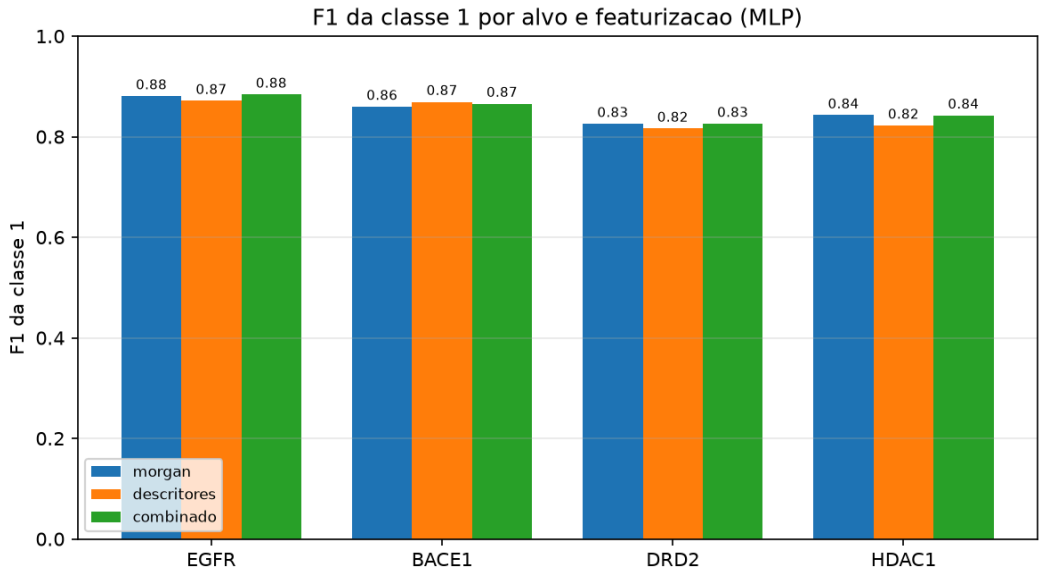
A etapa 3 do fluxo, padronização, parece um detalhe técnico. O slide 8 mostra que é ela que decide se o modelo funciona.

9 Resultados: Análise F1 classe C1

Alvo	Melhor representação	F1 ativa	IC 95%	ROC-AUC	Referência ingênua (F1 c1) - prever a classe majoritária (ativa)
EGFR	Combinado	**0,8840**	0,871–0,896	0,9023	0,7831
BACE1	Descritores	0,8693	0,855–0,884	0,8934	**0,7632**
HDAC1	*Fingerprint*	0,8428	0,823–0,860	0,8996	**0,7275**
DRD2	Combinado	0,8259	0,806–0,844	0,8744	**0,6984**

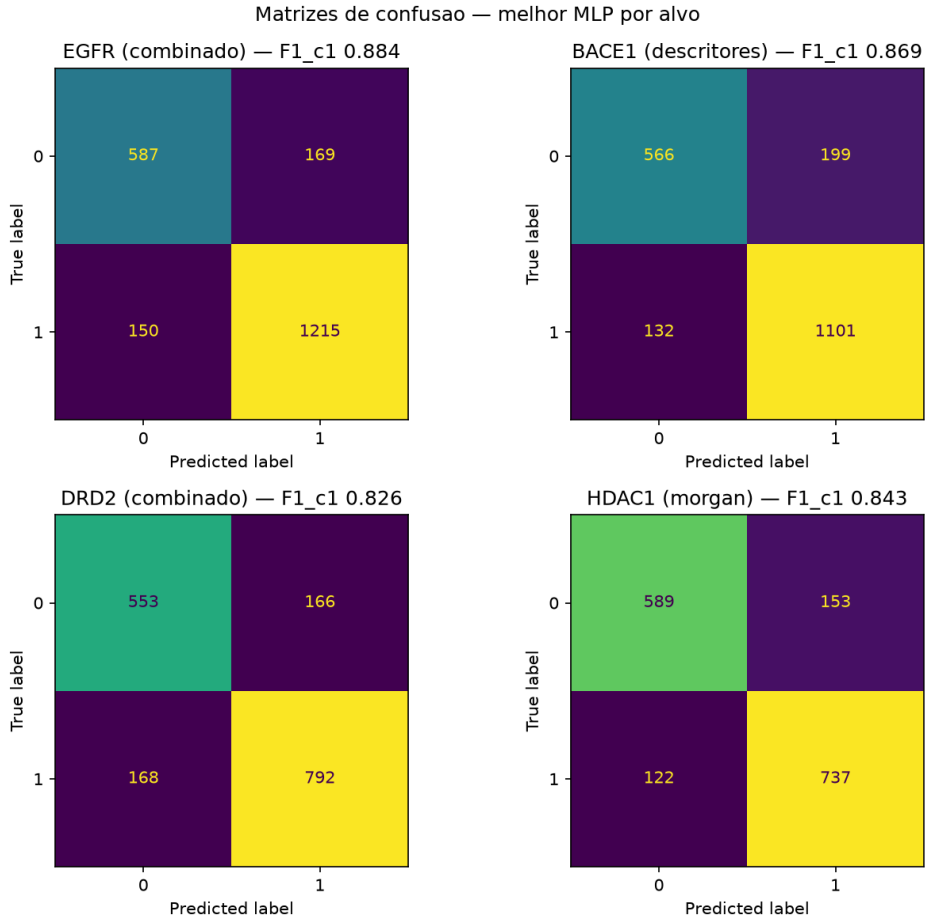
As três representações empatam

- Objetivo: selecionar moléculas para ensaio.
- **Falso negativo**: erro mais custoso descarta ativa, sem recuperação.
- **Falso positivo**: só consome um ensaio.
- Foco: **revocação e F1 da classe 1**.
- Cada alvo fica **dentro do mesmo intervalo de confiança,** a diferença **não é conclusiva.**



As três barras de cada alvo são praticamente da mesma altura

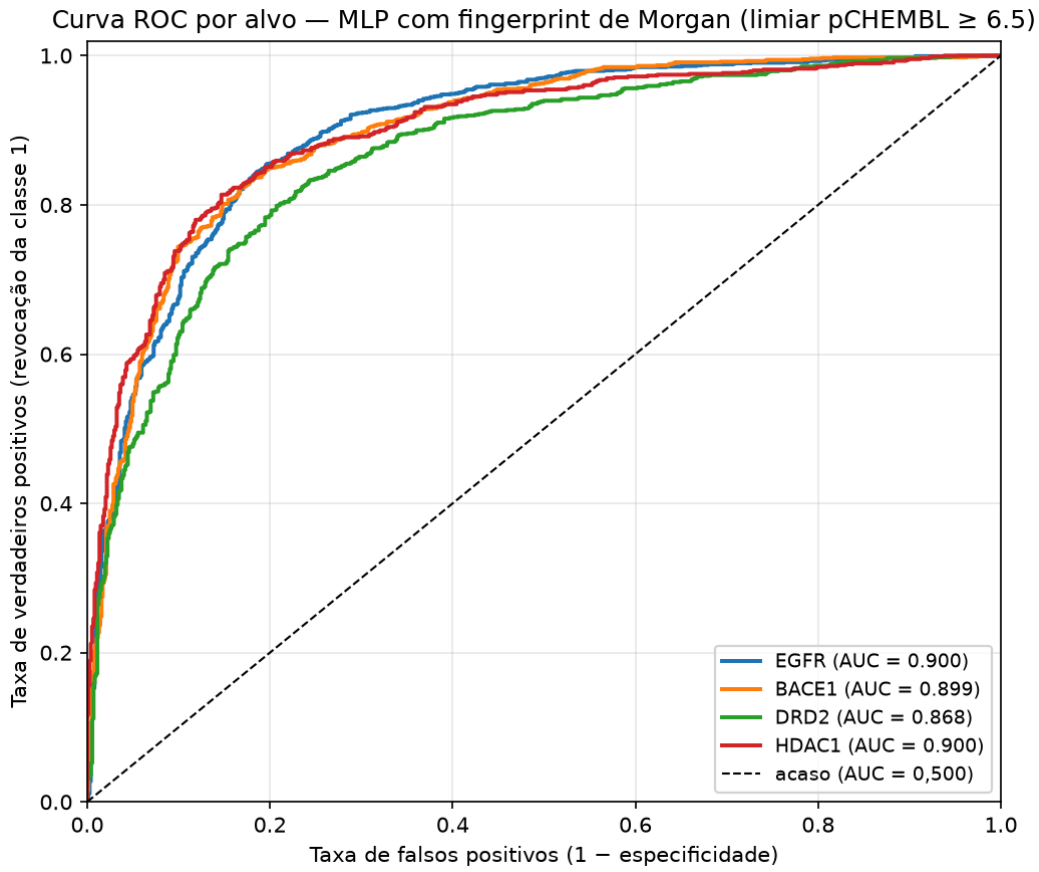
10 Resultados: Matriz de confusão



Análise

Considerando o falso negativo como o erro mais custoso, os modelos deixam de identificar entre 10,7% e 17,5% das moléculas ativas.

11 Resultados: Curva ROC



Análise

Curvas dos quatro alvos na mesma representação (fingerprint de Morgan). EGFR, BACE1 e HDAC1 se sobrepõem, DRD2 fica abaixo o que confirma a ordem de dificuldade nessas classe.

12 Resultado: influência da padronização

Alvo	ROC-AUC com padronização	ROC-AUC sem	F1 ativa sem
EGFR	**0,9023**	0,5115	0,7864
BACE1	**0,9049**	0,4809	0,0000
DRD2	**0,8744**	0,5126	0,7224
HDAC1	**0,9120**	0,5090	0,7014

Sem padronizar (StandardScaler) e mantendo os mesmos hiperparâmetros, a ROC-AUC cai para **0,48–0,51** nos quatro alvos, o modelo vira um **sorteio**. No BACE1 não identifica **nenhuma** das 1.233 moléculas ativas F1 c1 = 0.

Por quê?

A rede soma todos os atributos na mesma conta. Sem padronizar:

Ordens de grandeza

Massa molecular	**~300**
Nº de anéis	**0 a 5**
Bits do *fingerprint*	**0 ou 1**

A massa domina a conta e os demais atributos somem.

Cuidado com uma métrica só

Em três alvos, o F1 *sem* padronização ainda parece razoável (0,70–0,79). É ilusão, a ROC-AUC de 0,51 revela que não há classificação alguma.

13 Conclusão

1 **Padronização é indispensável**
Única transformação cuja ausência **inviabiliza** o modelo.

2 **Representação não é determinante**
Fingerprint, descritores e combinação **empatam** → escolher o mais barato.

3 **Limiar muda o equilíbrio, não a capacidade**
Subir o corte derruba o F1, mas a **ROC-AUC se mantém**.

4 **Hiperparâmetros atingiu um platô**
Teste de GRID 6 vezes maior não mudou o resultado no teste.

5 **Bioatividade alta não garante bom medicamento**
A predição indica um *hit* e filtros candidatos com **ADMET (Absorção, Distribuição, Metabolismo, Excreção e Toxicidade)** devem ser combinados.

Obrigado! Perguntas?